

# Praca Dyplomowa Magisterska

Maciej Pleban  
196195

## **Analiza rynku kryptowalut** Cryptocurrency market analysis

Praca dyplomowa na kierunku:  
Informatyka i Ekonometria

Praca wykonana pod kierunkiem  
dr Aleksandry Matuszewskiej-Janicy  
Instytut Ekonomii i Finansów  
Katedra Ekonometrii i Statystyki

Warszawa, rok 2023



SZKOŁA GŁÓWNA  
GOSPODARSTWA  
WIEJSKIEGO

Wydział Zastosowań  
Informatyki  
i Matematyki



### **Oświadczenie Promotora pracy**

Oświadczam, że niniejsza praca została przygotowana pod moim kierunkiem i stwierdzam, że spełnia warunki do przedstawienia tej pracy w postępowaniu o nadanie tytułu zawodowego.

Data .....

Podpis promotora .....

### **Oświadczenie autora pracy**

Świadom odpowiedzialności prawnej, w tym odpowiedzialności karnej za złożenie fałszywego oświadczenia, oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami prawa, w szczególności ustawą z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (Dz.U. 2019 poz. 1231 z późn. zm.).

Oświadczam, że przedstawiona praca nie była wcześniej podstawą żadnej procedury związanej z nadaniem dyplomu lub uzyskaniem tytułu zawodowego.

Oświadczam, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

Przyjmuję do wiadomości, że praca dyplomowa poddana zostanie procedurze antyplagiatowej.

Data .....

Podpis autora pracy .....



## **Streszczenie**

### **Analiza rynku kryptowalut**

Niniejsza praca dotyczy sprawdzenia, czy pewne zjawiska występujące na giełdach tradycyjnych, występują także na rynkach kryptowalut. Praca została podzielona na trzy części. W pierwszej zostały poruszone zagadnienia teoretyczne, wprowadzenie do poruszonego problemu, pewne założenia dotyczące wybranych metod, jak i przegląd literatury. W drugiej części pracy przedstawiona została metodyka, którą wykorzystano w pracy: analizę efektu dnia tygodnia, analizę zdarzeń i analizę wolumenu obrotu. Przedstawiono wybrane kryptowaluty, jak również dostosowano pierwotne wzory do specyfiki kryptowalut. W ostatniej części zaprezentowane zostały wyniki empiryczne, otrzymane wnioski, jak i podsumowanie pracy.

Słowa kluczowe – analiza dnia tygodnia, analiza zdarzeń, analiza wolumenu obrotów, kryptowaluty

## **Summary**

### **Cryptocurrency market analysis**

This work is about checking whether certain phenomena occurring on traditional stock exchanges also occur on cryptocurrency markets. The work was divided into three parts. The first one deals with theoretical issues, an introduction to the problem, some assumptions regarding selected methods, as well as a review of the literature. The second part of the work presents the methodology that was used in the work: analysis of the effect of the day of the week, analysis of events and analysis of the trading volume. Selected cryptocurrencies were presented, as well as the original formulas were adapted to the cryptocurrency specification. In the last part, the empirical results, conclusions and the summary of the work are presented.

Keywords – day of the week analysis, event analysis, volume analysis, cryptocurrencies



## Spis Treści

Wstęp .....	9
1. Charakterystyka funkcjonowania rynku kryptowalut.....	12
1.1. Blockchain.....	12
1.2. Podział kryptowalut .....	13
1.3. Przegląd literatury .....	15
2. Metody wykorzystane w analizie empirycznej.....	19
2.1. Efekt dnia tygodnia .....	19
2.2. Analiza zdarzeń.....	21
2.3. Analiza wolumenu obrotów .....	25
3. Wyniki empiryczne.....	29
3.1. Efekt dnia tygodnia .....	29
3.2. Analiza zdarzeń.....	33
3.3. Analiza wolumenu obrotów .....	35
4. Wnioski.....	41
Podsumowanie .....	43
Spis rysunków.....	45
Spis tabel.....	45
Bibliografia .....	46





# Wstęp

Kryptowaluty, czyli waluty cyfrowe są alternatywą dla standardowych walut. Są one oparte na algorytmach szyfrujących, co pozwala wymieniać się nimi między danymi osobami bez potrzeby korzystania z usług stron trzecich, takich jak np. banki. Umożliwiają bezpośrednie połączenie cyfrowe, poprzez przejrzysty proces, pokazując kwotę finansową, ale nie tożsamość osób przeprowadzających transakcję. Sieć składa się z „łańcucha” komputerów, z których wszystkie są wymagane do zatwierdzenia wymiany i zapobiegania powtórzenia tej samej transakcji (Business, 2018).

Tradycyjne waluty nazywane inaczej fiducyjnymi (ang. *FIAT money*), mają z kryptowalutami pewne podobieństwa. Najprościej rzecz ujmując, waluty fiducyjne to legalne środki płatnicze, których wartość ustalana i czerpana jest przez rząd, który go wydaje, a nie z fizycznego dobra lub towaru, takiego jak złoto czy srebro. Z kolei kryptowaluty dużą część swojej wartości opierają na spekulacji, czyli akceptacji danej ceny, przez osoby na całym świecie. Są one również podzielne – tak jak euro można podzielić na 100 centów, 1 Bitcoin (BTC) można podzielić na 100 000 000 mniejszych jednostek zwanych satoshi. Można je między sobą przysyłać, a także używać do płacenia za towary i usługi (Binance, 2019).

Kryptowaluty zyskały na popularności właśnie przez cechy, które odróżniają je od walut fiducyjnych. W przeciwieństwie do walut tradycyjnych kryptowaluty nie są emitowane przez rząd. Zamiast tego wiele kryptowalut jest zdecentralizowanych, więc żaden pojedynczy organ nie może zdecydować o emisji większej liczby kryptowalut i tym samym osłabić ich wartość. Zdecentralizowane kryptowaluty są samowystarczalne i nie wymagają stron trzecich do zatwierdzania transakcji. Ponieważ transakcje te są weryfikowane za pomocą technologii blockchain, wszystkie są trwale zapisane i nieodwracalne, dzięki czemu są one szczególnie bezpiecznym sposobem wymiany (Binance, 2021).

Kryptowaluty nie są jednak tworem perfekcyjnym i posiadają także wady, z czym wiąże się wiele niebezpieczeństw. Niektóre popularne kryptowaluty doświadczyły ekstremalnej zmienności cen, co może ograniczyć ich wykorzystanie i negatywnie wpłynąć na siłę nabywczą. Aktywa cyfrowe mogą być podatne na kradzież online, zapomnienie hasła lub przypadkową utratę. Przy mniejszej liczbie pośredników, a czasem

wręcz ich braku, ich odzyskanie może być jeszcze trudniejsze niż w przypadku walut FIAT, a często wręcz niemożliwe. Ponieważ nie są one obecnie wspierane przez rząd, ochrona aktywów, przechowywanie lub ubezpieczenie jest zależne od platformy kryptowalutowej (TradeStation, 2020).

Jako że kryptowaluty są w pewnym stopniu podobne do walut tradycyjnych, można nimi handlować na giełdach kryptowalut w sposób niemal identyczny. Dlatego też celem niniejszej pracy jest sprawdzenie, czy na rynku kryptowalut występują podobne zjawiska, jakie zauważono na rynku walut tradycyjnych. Kryptowaluty to temat dosyć nowy i w dalszym ciągu są prowadzone badania nad tym instrumentem, dlatego też badanie prezentowane w tej pracy może przyczynić się lepszemu zrozumieniu funkcjonowania rynku kryptowalut.

Celami prezentowanego badania są:

(1) Sprawdzenie występowania efektu dnia tygodnia w stopach zwrotu analizowanych kursów kryptowalut oraz w ich zmienności (analiza efektu dnia tygodnia jest zaliczana do grupy metod sprawdzających efektywność informacyjną instrumentów finansowych).

(2) Przeprowadzenie analizy zdarzeń, a w szczególności sprawdzenie wpływu wybuchu wojny na Ukrainie na rynek kryptowalut.

(3) Ocena relacji długookresowych i krótkookresowych pomiędzy notowaniami badanych kryptowalut.

Próba badawcza obejmowała notowania dzienne czterech kryptowalut (BTC, BNB, XMR i BAT w USD) z okresu (2018 - 2022).

Kryptowaluty zostały wybrane po jednej z każdego rodzaju, wymienionych w podrozdziale 1.2 Podział kryptowalut, aby lepiej zobrazować wpływ danych wydarzeń na badane wskaźniki.

Dane wykorzystane w analizie pochodzą z serwisu Yahoo Finance, a dane na temat indeksów giełdowych z serwisu stooq.pl i obejmują lata 2018 – 2022. Analiza została przeprowadzona w programie Gretl oraz przy wykorzystaniu skryptów napisanych w języku Python.

W rozdziale pierwszym przybliżone zostały mechanizmy, na których opiera się funkcjonowanie kryptowalut wraz z podziałem na różne ich rodzaje, towarzyszące im charakterystyki i ich przykłady. W kolejnym rozdziale przedstawione zostały metody, jakie wykorzystano w empirycznej części pracy tj. efekt dnia tygodnia, analizę zdarzeń i analizę wolumenu obrotów. Pierwotnie metody te zostały użyte na rynkach tradycyjnych, dlatego też musiały one zostać dopasowane do rynku kryptowalut, który działa nieco inaczej.

W ostatnim rozdziale zaprezentowano wyniki analiz empirycznych w ramach przeprowadzonych w ramach badań, a także wnioski, jakie z nich wynikają.

# 1. Charakterystyka funkcjonowania rynku kryptowalut

W tym rozdziale została przedstawiona definicja i charakterystyka blockchainu, czyli technologii, która stoi za większością kryptowalut. Następnie przedstawiono podział kryptowalut na różne ich rodzaje, wraz z ich charakterystykami i przykładami. Na końcu rozdziału znajduje się przegląd literatury, składający się głównie z prac skupiających się na rynkach tradycyjnych, ale też literaturze związanej ściśle z kryptowalutami.

## 1.1. Blockchain

Według definicji podanej przez (Oracle, 2022), technologia blockchain umożliwia grupie wybranych uczestników dzielenie się danymi, a dzięki usługom blockchain w chmurze dane transakcyjne z wielu źródeł można łatwo gromadzić, integrować i udostępniać. Dane są podzielone na współużytkowane bloki, połączone z unikatowymi identyfikatorami w formie skrótów kryptograficznych. Blockchain można zatem określić jako historyczny zapis transakcji. Każdy blok jest „powiązany” z poprzednim blokiem w sekwencji i zapisywany w niezmienny sposób w sieci *peer-to-peer*. Kryptograficzna technologia zaufania i pewności stosuje unikalny identyfikator — lub cyfrowy odcisk palca — do każdej transakcji.

Nieodłączną częścią tego łańcucha są zaufanie, odpowiedzialność, przejrzystość i bezpieczeństwo. Umożliwia to organizacjom i partnerom biznesowym wszelkiego rodzaju dostęp do danych i udostępnianie ich. Jest to zjawisko znane jako zaufanie oparte na konsensusie stron trzecich. Wszyscy uczestnicy prowadzą zaszyfrowany zapis każdej transakcji w ramach zdecentralizowanego, wysoce skalowalnego i odpornego mechanizmu rejestrowania. Zdecentralizowane pojedyncze źródło informacji zmniejsza koszty wdrażania zaufanych interakcji biznesowych między stronami, które mogą nie mieć do siebie pełnego zaufania. W rejestrze blockchain udostępnianym za uprzednią zgodą, który jest używany przez większość przedsiębiorstw, uczestnicy są upoważnieni do uczestnictwa w sieci, a każdy uczestnik prowadzi zaszyfrowany zapis wszystkich transakcji (Oracle, 2022). Każda firma lub grupa firm, która potrzebuje bezpiecznego, współdzielonego rejestru transakcji w czasie rzeczywistym, może skorzystać z tej unikalnej technologii. Nie ma jednego miejsca, w którym wszystko jest przechowywane,

co poprawia bezpieczeństwo i dostępność oraz eliminuje główny punkt ryzyka, czyli awarię punktu centralnego (Oracle, 2023).

Kryptowaluty można kupić albo wydobywać. Wydobywanie w kopalni kryptowalut to zajęcie polegające na rejestrowaniu transakcji na łańcuchu bloków przy użyciu wyspecjalizowanego sprzętu komputerowego. Protokół danej waluty z reguły przewiduje wynagrodzenie dla osób wykonujących obsługujących transakcje i wyliczających nowe krypto (Business, 2022).

## **1.2. Podział kryptowalut**

Mimo że Bitcon (BTC) był pierwszą kryptowalutą, która zyskała popularność, obecnie istnieje wiele innych kryptowalut. W zależności od ich konstrukcji, zastosowania lub przypadku użycia oraz innych kryteriów, wyróżnić można co najmniej cztery różne rodzaje. W niniejszej pracy skupiono się na tokenach, czyli cyfrowych reprezentacjach określonego zasobu lub narzędzia w blockchainie. Są one osadzone w samo wykonujących się programach komputerowych lub kodach i mogą działać bez platformy innej firmy. Wszystkie informacje zawarte w tym punkcie zostały opracowane na podstawie opracowania (Software Testing Help, 2023).

### **Tokeny użytkowe (utility tokens)**

Tokeny użytkowe są uważane za kupony lub bony, ale zasadniczo są to jednostki cyfrowe reprezentujące wartość w blockchainie. Innymi słowy, token zapewnia określony dostęp do produktu lub usługi prowadzonej, lub obsługiwanej przez emitenta tokena. Możliwe jest uzyskanie dostępu poprzez zakup tokena i wymianę na określoną wartość dostępu do produktu lub usługi. Wyróżniamy dwie główne cechy tokenów:

- posiadacz zyskuje prawo do produktu lub usługi odpowiadającej wartości tokena, ale nie do jego własności. Na przykład dostęp do produktu lub usługi po obniżonych opłatach, lub za darmo, dopóki posiadane są tokeny,
- tokeny użytkowe są lepiej rozumiane z perspektywy regulacyjnej w tym sensie, że z założenia nie podlegają regulacji. Posiadacz tokena nie posiada odpowiednika akcji czy obligacji lub innego aktywa regulowanego przez ustawy finansowe, tak więc mogą całkowicie stracić na wartości na koszt posiadacza.

Przykładami tokenów użytkowych są: Basic Attention Token, Golem, Sirin Labs Token.

### **Tokeny płatnicze (*payment tokens*)**

Tokeny płatnicze są to tokeny używane do kupna i sprzedaży dóbr i usług na platformach cyfrowych bez pośrednika, w odróżnieniu od tradycyjnych finansów. Większość tokenów należy do tej kategorii, natomiast nie każdy token użytkowy może być tokenem płatniczym.

Główne cechy tokenów płatniczych są następujące:

- zwykle są hybrydami innych tokenów,
- tokeny płatnicze nie stanowią i nie mogą być inwestowane jako papiery wartościowe. Dlatego też nie podlegają regulacji finansowej jako papiery wartościowe,
- tokeny płatnicze mogą, ale nie muszą gwarantować posiadaczom dostępu do produktu lub usługi ani teraz, ani w przyszłości.

Przykładami tokenów płatniczych są: Bitcoin, Ethereum, Monero.

### **Tokeny wymiany (*exchange tokens*)**

Są to zwykle tokeny, które otrzymują nazwę po giełdach kryptowalut, które je emitują. Mimo że można ich używać poza ich rodzimymi środowiskami, używa się ich przede wszystkim do ułatwienia wymiany między innymi tokenami lub jako płatności za opłaty towarzyszące wymianie.

Główne cechy tokenów wymiany są następujące:

- mogą je emitować centralizowane giełdy z lub bez zdecentralizowanych platform, lub własnych blockchainów,
- mogą one służyć do tańszego płacenia za opłaty, zwiększania płynności czy udzielania darmowych rabatów,
- w celu zwiększenia płynności, giełdy wykorzystują je, aby zachęcić ludzi do udziału w projektach.

Przykładami tokenów wymiany są: Binance Coin, Gemini Dollar, OKB.

### **Tokeny prywatności (*privacy tokens*)**

Są to kryptowaluty używane do zastosowań związanych z prywatnością, ponieważ ich kod sprzyja lepszej prywatności, niż byłoby to w przypadku Bitcoina

i kryptowalut z głównego nurtu. Istnieje wiele powodów, dla których niektóre jednostki potrzebowałyby lepszej prywatności w transakcjach kryptowalutowych. Stosuje się je zwykle w przypadku transakcji wysoce wrażliwych. Te kryptowaluty zawierają różne metody zapewnienia prywatności transakcji, np. techniki anonimowości, takie jak CoinJoin i transakcje offline. Jest to dodatek do technik stosowanych w kryptowalutach głównego nurtu jak np. brak wiązania nazwisk z realnego świata z adresami kryptowalut i szyfrowanie blockchain. Tak więc spośród wszystkich wymienionych kryptowalut, ten rodzaj zapewnia największy poziom poufności.

Przykładami tokenów prywatności są: Monero, Zcash, Dash.

### **1.3. Przegląd literatury**

Ponieważ temat kryptowalut jest stosunkowo nowy (pierwsze kryptowaluty powstały w 2008 roku), literatura w tej dziedzinie dopiero się rozwija i skupia głównie na technologii blockchain, skalowalności, decentralizacji i problemach dotyczących ich regulacji. Nie weszły one jeszcze do głównego nurtu i dla niektórych wciąż są tajemnicą, a często też uważane są za niebezpieczne i bardzo ryzykowne instrumenty, co do pewnego stopnia jest prawdą.

Rynek kryptowalut funkcjonuje od około 15 lat, zatem okres badawczy jest wystarczający, aby zbadać własności szeregów czasowych dotyczących notowań kryptowalut. Adrian Cheung (Cheung, et al., 2015), Gerald Dwyer (Dwyer, 2015) i Jon Carrick (Carrick, 2016) wskazują, że jest on znacznie bardziej zmienny niż inne rynki. Z kolei Bartos (Bartos, 2015) stwierdza, że rynek ten natychmiast reaguje na pojawienie się nowych informacji i dlatego można go określić jako efektywny informacyjnie (hipoteza rynku efektywnego informacyjnie w odniesieniu do rynku kryptowalut została opisana na przykład w (Latif, 2017), (Kang, 2022), (Bariviera, 2017), (Sigaki, et al., 2019)).

Jako że kryptowaluty są podobne do tradycyjnych walut, powinny one działać na podobnych zasadach. Efekt dnia tygodnia był jedną z pierwszych anomalii kalendarzowych, które zostały zauważone na rynku. Fields w swojej pracy (Fields, 1931) pokazał, że najlepszym dniem do handlu na giełdzie jest sobota. (Cross, 1973) dostarczył dowody na statystyczne różnice w piątkowo-poniedziałkowych danych na amerykańskim rynku akcji. Z kolei na GPW w Warszawie, Landmesser (Landmesser, 2006) wykazała, że najczęściej wysokie stopy zwrotu osiągane są w poniedziałki i piątki. Na rynku

kryptowalut natomiast Caporale i Plastun (Caporale & Plastun, 2019) pokazali, że w przypadku Bitcoina występują niestandardowe dodatnie stopy zwrotu w poniedziałki. Analiza dnia tygodnia w kryptowalutach została przedstawiona w (Caporale & Plastun, 2019), (Plastun, et al., 2019) i (Yaya & Ogbonna, 2019) dając niejednoznaczne wyniki o występowaniu tego efektu na rynku kryptowalut.

Interesującym podejściem jest badanie wpływu zdarzenia lub grupy zdarzeń na wybraną zmienną. Jest to tak zwana analiza zdarzeń, często przeprowadzana przy okazji rynków finansowych, chociażby przez Kujawę i Ostrowską (Kujawa & Ostrowska, 2016), czy Zarembę i Płotnickiego (Zaremba & Płotnicki, 2015). W kontekście kryptowalut owo badanie zostało przeprowadzone na przykładzie Bitcoina przez Diaconășu, Mehdiian i Stoica (Diaconășu, et al., 2022), sugerując że inwestorzy w przypadku zdarzeń pozytywnych wydają się działać bardziej racjonalnie niż w przypadku negatywnych. Zwykle badanie to przeprowadza się na stopach zwrotu badanego instrumentu finansowego, które ma swoje zastosowanie w prawie i ekonomii np. aby sprawdzić wpływ regulacji na ceny akcji.

Analiza wolumenu obrotów jest traktowana jako analiza uzupełniająca. Wolumeny obrotu i ceny akcji to podstawowe parametry, których kształtowanie się stanowi podstawę podejmowania decyzji przez inwestorów preferujących analizę techniczną, a także są naturalną konsekwencją działań inwestorów (Widz, 2017). Dlatego też są często brane pod uwagę w analizie rynków finansowych.

Z badań zajmujących się analizą finansowych szeregów czasowych (Bollerslev, 1986), (Box & Jenkins, 1986), (Tsay, 2002), (Piontek, 2002), (Piontek, 2003), wykazano występowanie w szeregach stóp zwrotu m.in.:

- efektu leptokurtozy i grubych ogonów rozkładów stóp zwrotu, co oznacza, że prawdopodobieństwo wystąpienia dużych, nietypowych zmian kursu (duże co do wartości bezwzględnej stopy zwrotu) jest większe niż gdyby stopy zwrotu pochodziły z rozkładu normalnego,
- efektu skośności rozkładów stóp zwrotu,
- efektu autokorelacji stóp zwrotu, szczególnie w okresach o małej zmienności,
- efektu długiej pamięci w szeregach zmienności (wariancji), czyli istotnie znaczących współczynników wysokich rzędów autokorelacji kwadratów stóp zwrotu,



- efektu dźwigni - efektu ujemnego skorelowania poziomu kursów i poziomu zmienności stóp zwrotu, czyli asymetrycznego wpływu informacji pozytywnych i negatywnych na poziom przyszłej wariancji,
- efektu skupiania (gromadzenia) zmienności (*volatility clustering*), co oznacza, że zarówno małe, jak i duże zmiany kursu następują seriami, a tym samym oznacza niestałość wariancji stóp zwrotu w czasie.

Analizę kryptowalut pod kątem szeregów czasowych podjęli np. (Fleischer, et al., 2022).

Na rynku finansowym w odniesieniu do oceny procesu inwestowania stosuje się głównie dwa podejścia: analizę techniczną i fundamentalną. Naukowcy stosujący tę pierwszą kierują się następującymi założeniami (Tarczyński, 2002):

- wartość rynkową akcji określa relacja popyt – podaż,
- kurs rynkowy uzależniony jest zarówno od czynników fundamentalnych, jak i od czynników nieracjonalnych,
- ceny akcji układają się w trendy,
- wzorce zmian cen są powtarzalne,
- podstawę analiz stanowi długoterminowy trend, na który nakładają się trendy niższych rzędów.

Z tych założeń można wywnioskować, że naukowcy uważają, że przyszłe ceny akcji da się przewidzieć na podstawie danych historycznych. Natomiast jeden z największych polskich spekulantów Rafał Zaorski, uważa rynek za żywy organizm, który ciągle się zmienia, a próby przewidzenia przyszłej ceny za pomocą analizy technicznej, jak jazda samochodem, patrząc w tył (Trading Jam, 2018). Analizy technicznej pod kątem kryptowalut używali w swoich pracach m.in. (Ilham, et al., 2022), (Svogun & Bazán-Palomino, 2022), (ANGHEL, 2021).

Założeniem analizy fundamentalnej jest twierdzenie, że można wyznaczyć rzeczywistą wartość akcji, wolną od wpływu emocji i zniekształceń poznawczych inwestorów. Wyznaczanie wartości rzeczywistej akcji polega na oszacowaniu prognozowanych zysków spółki oraz wyznaczeniu stopy dyskontowej, po jakiej przeliczane są przyszłe zyski (Zielonka, 2006). Analizy fundamentalnej pod kątem kryptowalut podjęli się np. (Wei, et al., 2023) czy (Bhambhwani, et al., 2019).

Z analizą fundamentalną wiążą się jednak pewne niebezpieczeństwa, ponieważ na rynkach finansowych często pojawiają się czynniki, które nie są przewidywalne i mogą wpłynąć na ceny aktywów. Takie czynniki to na przykład niestabilność geopolityczna, zmienne warunki gospodarcze, wprowadzenie nowych regulacji, a także czynniki psychologiczne, takie jak euforia lub panika inwestorska.

Dlatego też interesującym tematem jest aspekt finansów behawioralnych, zwanych także psychologią rynku finansowego. Jest to deskryptywne podejście do rynku, objaśniające procesy poznawcze i motywacyjno-emocjonalne u inwestorów. W przeciwieństwie do analizy fundamentalnej, zamiast uwarunkowań ekonomicznych, skupia się na uwarunkowaniach psychologicznych, czyli odnoszących się do indywidualnych zachowań inwestorów (Zielonka, 2006).

Psychologia dowodzi, że na rynkach finansowych dochodzi do pewnych zjawisk, które przeszkadzają inwestorom w racjonalnym inwestowaniu. Jednym z najczęściej występujących zachowań są zachowania stadne. Ludzie są podatni na wpływ innych, zarówno realny jak i wyimaginowany. Szczególną rolę w tym procesie odgrywa informacyjny wpływ społeczny, czyli przekonanie, że zachowanie innych stanowi wiarygodne źródło informacji. Ludzie często naśladują zachowanie innych, uważając, że jeśli wiele osób działa w ten sam sposób, to oznacza, że poprawnie interpretują dane okoliczności (Zielonka, 2006). Wynika z tego, że emocje mają ogromny wpływ na decyzje finansowe, szczególnie w momentach niepewności i strachu. Dlatego też, być może warto rozważyć analizę sentymentu, chociażby biorąc pod uwagę wskaźnik chciwości i strachu (Fear and Greed Index), który w pewien sposób odzwierciedla nastroje panujące na rynku. Ekonomią behawioralną na rynku kryptowalut zajmowali się m. in. (Ballis & Verousis, 2022), (Mnif, et al., 2022).

## 2. Metody wykorzystane w analizie empirycznej

W niniejszym rozdziale przedstawione zostały metody wykorzystane w części empirycznej pracy tj. efekt dnia tygodnia, analiza zdarzeń i analiza wolumenu obrotów. Równania regresji pierwotnie użyte w analizach tradycyjnego rynku finansowego, na których opiera się praca, zostały zmodyfikowane w taki sposób, aby pasowały do badanych szeregów czasowych z rynku kryptowalut.

Do przeprowadzenia analizy występowania efektu dnia tygodnia został użyty program Gretl, z kolei do pozostałych analiz wykorzystano skrypty napisane w języku Python.

### 2.1. Efekt dnia tygodnia

Efekt dnia tygodnia dotyczy różnic w stopach zwrotu z inwestycji w instrumenty finansowe (w tym wypadku w kryptowaluty) w kolejnych dniach tygodnia. Jest to często przeprowadzana analiza, dzięki której wykazano na przykład występowanie efektu poniedziałku na rynku amerykańskim, gdzie przeciętne poniedziałkowe stopy zwrotu są znacznie niższe niż w pozostałe dni tygodnia (Cross, 1973), (French, 1980). Ponieważ kryptowaluty funkcjonują przez 7 dni tygodnia, do modelu zostały dodane zmienne, które reprezentują także soboty i niedziele.

Anomalie sezonowe związane z występowaniem efektu dnia tygodnia, przebadano wstępnie wykorzystując prosty model regresji liniowej, zawierający siedem zmiennych zero-jedynkowych, po jednej dla każdego dnia tygodnia opisany wzorem (1):

$$r_t = \gamma_1 D_{1t} + \gamma_2 D_{2t} + \gamma_3 D_{3t} + \gamma_4 D_{4t} + \gamma_5 D_{5t} + \gamma_6 D_{6t} + \gamma_7 D_{7t} + \varepsilon_t \quad (1)$$

gdzie:

$r_t$  — dzienna logarytmiczna stopa zwrotu z inwestycji w kryptowalutę  
 $D_{jt}$  — dla  $j = 1, 2, \dots, 7$ , zmienna zero-jedynkowa przybierająca wartość 1 w wypadku, gdy korespondujący z nią  $j$ -ty dzień tygodnia jest poniedziałkiem, wtorkiem, środą, czwartkiem, piątkiem, sobotą, niedzielą lub wartość 0 w przeciwnym przypadku (dla  $j=1, 2, \dots, 7$ )

$\gamma_j$  - dla  $j = 1, 2, \dots, 7$ , parametry modelu przy zmiennych binarnych.

$\varepsilon_t$  — składnik losowy

Warto dodać, że jeżeli w modelu mamy zmienne binarne reprezentujące wszystkie warianty, to ze względu na współliniowość nie uwzględniamy wyrazu wolnego. W przypadku uwzględnienia wyrazu wolnego należy pominąć jeden z wariantów (Borkowski, et al., 2007).

Parametry równania (1) mogą być estymowane przy użyciu klasycznej metody najmniejszych kwadratów.

Ze wspomnianym podejściem wiążą się dwa problemy: uzyskane z modelu reszty mogą wykazywać autokorelację oraz wariancja reszt nie zawsze jest stała w czasie.

Rozwiązaniem pierwszego problemu jest zastosowanie następującego modelu autoregresyjnego  $AR(s)$ . Przy uwzględnieniu zmiennych binarnych reprezentujących efekt dnia tygodnia model ten przyjmie postać opisaną wzorem (2):

$$r_t = \gamma_1 D_{1t} + \gamma_2 D_{2t} + \gamma_3 D_{3t} + \gamma_4 D_{4t} + \gamma_5 D_{5t} + \gamma_6 D_{6t} + \gamma_7 D_{7t} + \sum_{i=1}^s \alpha_i r_{t-i} + \varepsilon_t \quad (2)$$

gdzie:

$r_{t-i}$  – stopa zwrotu opóźniona o  $i$  okresów, tzw. zmienna autoregresyjna,

$\alpha_i$  – parametry przy zmiennej autoregresyjnej; pozostałe oznaczenia jak we wzorze (1).

Drugi problem można rozwiązać uwzględniając zmienność wariancji reszt w modelach typu ARCH. Dzięki zależności wariancji od poprzednich wartości szeregu, ARCH dobrze modeluje efekt grupowania danych. Uogólniona wersja tego modelu –  $GARCH(p, q)$  – zaproponowana została przez Bollersleva (Bollerslev, 1986) i dla analizowanego przez nas szeregu stóp zwrotu przyjmuje następującą postać (3):

$$r_t = \gamma_1 D_{1t} + \gamma_2 D_{2t} + \gamma_3 D_{3t} + \gamma_4 D_{4t} + \gamma_5 D_{5t} + \gamma_6 D_{6t} + \gamma_7 D_{7t} + \sum_{i=1}^s \alpha_i r_{t-i} + \varepsilon_t,$$

gdzie  $\varepsilon_t | \Psi_{t-1} \sim N(0, \sigma_t^2)$

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (3)$$

$\sigma_t^2$  – reprezentuje równanie wariancji warunkowej,

$\alpha_i, \beta_j$  – parametry modelu.

Zakładamy, że składnik losowy  $\varepsilon_t$  ma warunkowy rozkład normalny ze średnią 0 i zmienną w czasie warunkową wariancją  $\sigma_t^2$ . Wymogiem specyfikacji jest  $\alpha_0 > 0, \alpha_i > 0, \beta_i > 0$  oraz  $\sum_{i=1}^p \beta_i + \sum_{i=1}^q \alpha_i < 1$ .

Efekty kalendarzowe mogą występować także w wariancji warunkowej. Dlatego też zgodnie z pozycją zawartą w pracy (Landmesser, 2006) model (3) zmodyfikowano włączając zmienne związane z efektem dnia tygodnia również do równania wariancji warunkowej:

$$\begin{aligned} r_t &= \gamma_1 D_{1t} + \gamma_2 D_{2t} + \gamma_3 D_{3t} + \gamma_4 D_{4t} + \gamma_5 D_{5t} + \gamma_6 D_{6t} + \gamma_7 D_{7t} + \sum_{i=1}^s \alpha_i r_{t-i} \\ &\quad + \varepsilon_t \\ \sigma_t^2 &= \delta_1 D_{1t} + \delta_2 D_{2t} + \delta_3 D_{3t} + \delta_4 D_{4t} + \delta_5 D_{5t} + \delta_6 D_{6t} + \delta_7 D_{7t} \\ &\quad + \sum_{i=1}^s \alpha_{i+1} \varepsilon_{t-i}^2 + \sum_{j=1}^s \beta_j \sigma_{t-j}^2 \end{aligned} \quad (4)$$

gdzie:

$\delta_j$  – dla  $j = 1, 2, \dots, 7$  parametry przy zmiennych binarnych reprezentujących efekt dnia tygodnia w modelu wariancji warunkowej; pozostałe oznaczenia jak w modelu (3).

Estymacji modeli uwzględniających efekt wariancji warunkowej (modele z równanie GARCH) dokonuje się najczęściej metodą największej wiarygodności (Landmesser, 2006).


## 2.2. Analiza zdarzeń

Powołując się na (Kujawa & Ostrowska, 2016) przeprowadzając analizę zdarzeń należy przyjąć hipotezę rynku efektywnego prowadzącą do podstawowego wniosku, że jeśli dane zdarzenie jest ważne, to powinno znaleźć niemalże natychmiastowe

odzwierciedlenie w cenie waloru. Klasyczne teorie finansów zakładają racjonalność uczestników rynku, co oznacza, że inwestorzy, podejmując decyzje inwestycyjne, działają w sposób, który zmaksymalizuje ich korzyści oraz właściwie zinterpretują napływające informacje. (Howells & Bain, 1999). Racjonalny inwestor w naturalny sposób powinien racjonalnie wybierać optymalne rozwiązanie spośród różnych alternatyw. W rzeczywistości, chociaż inwestorzy wiedzą, co jest dla nich najlepsze, nie zawsze dokonują najlepszych wyborów. Oddziaływanie na takie decyzje wynika z zaangażowania emocjonalnego inwestora oraz chęci podążania za tłumem (w literaturze przedmiotu opisywane jako zachowania stadne, których cechą charakterystyczną jest niska inteligencja).

Podstawowymi etapami badań analiz zdarzeń są (Gurgul, 2012):

1. definicja zdarzenia oraz określenie okna zdarzenia;
2. sprecyzowanie kryteriów doboru firmy/składników do próby;
3. wybór miar określających poziom oczekiwanej i nadwyżkowej stopy zwrotu;
4. estymacja modelu opisującego oczekiwaną stopę zwrotu, po wcześniejszym określeniu podstawowych parametrów, takich jak długość okna zdarzenia oraz umiejscowienie okna estymacyjnego względem okna zdarzenia;
5. weryfikacja hipotez początkowych;
6. interpretacja wyników oraz formułowanie wniosków.



Rysunek 1. Okna w analizie zdarzeń

Źródło: (Kujawa & Ostrowska, 2016)

gdzie:

$(T_0, T_1]$  – okno estymacji,

$[T_1, T_2]$  – okno zdarzenia,

$(T_2, T_3)$  – okno po zdarzeniu,

$D_0$  – dzień zdarzenia,

$D_1$  – pierwszy dzień po zdarzeniu,

$D_2$  – drugi dzień po zdarzeniu,

$D_{-1}$  – dzień przed zdarzeniem,

$D_{-2}$  – dwa dni przed zdarzeniem.

Na rysunku (Rysunek 1) graficznie zaprezentowano usytuowanie okna zdarzenia względem okna estymacyjnego. Miejsce okna estymacyjnego to w badaniach najczęściej okres bezpośrednio poprzedzający okno zdarzenia, ale nigdy nieprzylegający do dnia zdarzenia, co oznacza, że ostatni dzień okna estymacyjnego nie może oznaczać początku okna zdarzenia. Okno estymacyjne nie może zatem pokrywać się z oknem zdarzenia. W literaturze oczekiwane zwroty są obliczane na podstawie danych z okresu przed oknem zdarzenia (najczęściej stosowanym okresem) lub okresu po oknie zdarzenia lub kombinacji danych sprzed i po zdarzeniu. Długość okna zdarzenia w porównaniu do okna estymacyjnego powinna być relatywnie krótka. W literaturze mowa o tym, że szerokość okna zdarzenia powinna rozciągać się do pierwszego dnia po zdarzeniu, w którym nie zaobserwowano (Krivin, 2003):

- istotnej wartości zwykłej stopy zwrotu (dodatniej lub ujemnej);
- istotnej wartości zwykłego wolumenu (dodatniego lub ujemnego);
- istotnej wartości zwykłej wariancji (dodatniej lub ujemnej).

Szerokość okna zdarzenia oraz usytuowanie i długość okna estymacyjnego mogą być za każdym razem indywidualnie ustalana dla każdego składnika podlegającego badaniu z osobna, ale można również przyjąć założenie, że dla wszystkich składników przyjmuje się to samo okno zdarzenia, zaczynające się (dla przykładu) 2 dni przed zdarzeniem i kończące 2 dni po nim. Należy dodać, że w takich sytuacjach należy dokładnie przeanalizować, czy w oknie estymacji występują dodatkowe zdarzenia zakłócające związane z analizowanymi komponentami konwencjonalnymi lub alternatywnymi. Dla potrzeb niniejszej pracy, w każdym przypadku  $D_0$  oznacza dzień zdarzenia, np. dzień wydarzenia gospodarczego (notowanie na zamknięcie sesji lub na koniec dnia w zależności od składnika) i dla  $D_0$  obliczona została dzienna procentowa zmiana wartości indeksu lub ceny składnika.

W celu dokonania weryfikacji, czy zdarzenie miało oddziaływanie na notowania cen/wartości składnika inwestycyjnego, można dokonać obliczeń dodatkowej stopy zwrotu według wzoru (5):

$$AR_{it} = R_{it} - E(R_{it}) \quad (5)$$

gdzie:

$AR_{it}$  — dodatkowa stopa zwrotu z akcji  $i$  osiągnięta w okresie  $t$ ,

$R_{it}$  — rzeczywista stopa zwrotu z akcji  $i$  osiągnięta w okresie  $t$ ,

$E(R_{it})$  — oczekiwana stopa zwrotu z akcji  $i$  w okresie  $t$  w sytuacji, gdyby zdarzenie nie wystąpiło,

$t$  — dzień lub miesiąc w zależności od przyjętych do obliczeń danych i jednostki okna zdarzenia.

Następnie należy obliczyć oczekiwaną stopę zwrotu (6):

$$E(R_{it}) = K_i \quad (6)$$

gdzie:

$E(R_{it})$  — oczekiwana stopa zwrotu z akcji  $i$  w okresie  $t$ ,

$K_i$  — średnia stopa zwrotu z akcji  $i$  w okresie niezależnym.

Kolejnym krokiem jest obliczenie skumulowanej nadwyżkowej stopy zwrotu w oknie zdarzenia (7):

$$CAR_{it} = \sum_{t=1}^T AR_{it}, t = 1 \quad (7)$$

gdzie:

$CAR_{it}$  — skumulowana nadwyżkowa stopa zwrotu z akcji  $i$  osiągnięta w okresie obserwacji  $T$ ,

$T$  — okres obserwacji, przedział czasowy mierzony w dniach lub miesiącach,

$\sum^T AR_{it}$  — suma dodatkowych stóp zwrotu.

Ostatnim krokiem jest obliczenie średnich skumulowanych nadwyżkowych stóp zwrotu (8):



$$ACAR = \frac{\sum^T AR_{it}}{N} \quad (8)$$

gdzie:

$ACAR$  — średnia skumulowana dodatkowa stopa zwrotu,

$N$  — liczba składników badanej populacji,

$\sum^T AR_{it}$  — suma dodatkowych stóp zwrotu.

### 2.3. Analiza wolumenu obrotów

Analiza wolumenu obrotów jest ważnym narzędziem dla inwestorów, ponieważ wysoki wolumen może wskazywać na siłę trendu i potwierdzić, że zmiana cen jest trwała i nie jest spowodowana jedynie krótkotrwałym zainteresowaniem. Jest to narzędzie używane przez badaczy analizy technicznej.

W przeprowadzonej analizie brano pod uwagę następujące zmienne:

$P_t$  — cena kryptowaluty na zamknięcie notowań sesji  $t$ ,


$R_t$  — logarytmiczna stopa zwrotu kryptowaluty wyznaczona jako  $R_t = \ln P_t - \ln P_{t-1}$ ,

$D_t$  — zmienność stóp zwrotu kryptowaluty wyznaczona jako odchylenie standardowe stóp zwrotu z ostatnich 20 sesji z  $t$  włącznie,

$V_t$  — wolumen obrotu w czasie sesji  $t$ .

Okres badawczy podzielono na 7 podokresów na podstawie minimów i maksimów poziomu BTC (Rysunek 2), co pozwoliło na określenie zależności między zmiennymi w okresach zarówno wzrostów, jak i spadków na giełdzie:

- I okres: 1.01.2018–15.12.2018
- II okres: 16.12.2018–26.06.2019
- III okres: 27.06.2019–12.03.2020
- IV okres: 13.03.2020–13.04.2021
- V okres: 14.04.2021–20.07.2021
- VI okres: 21.07.2021–8.11.2021
- VII okres: 9.11.2021–31.12.2022



Rysunek 2. Poziom BTC na zamknięcie notowań w okresie od 1.01.2018 do 31.12.2022

Źródło: opracowanie własne

Badanie zależności między zmiennymi zostało przeprowadzone dla trzech par zmiennych:  $P_t$  i  $V_t$ ,  $R_t$  i  $V_t$  oraz  $D_t$  i  $V_t$  dla każdej z czterech kryptowalut. W pierwszej kolejności analiza dotyczyła zależności korelacyjnych na podstawie współczynników korelacji Pearsona (9) (Widz, 2017):

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y} \quad (9)$$

gdzie:

$\rho_{X,Y}$  — współczynnik korelacji Pearsona pomiędzy zmiennymi  $X$  i  $Y$ ,

$cov(X,Y)$  — kowariancja pomiędzy zmiennymi  $X$  i  $Y$ ,

$\sigma_X, \sigma_Y$  — odchylenie standardowe z populacji, odpowiednio  $X$  i  $Y$ .

Następnie zostało przeprowadzone badanie przyczynowości w sensie Grangera. Definicja przyczynowości w sensie Grangera mówi, że zmienna  $X_t$  jest przyczyną  $Y_t$ , jeżeli przyszłe wartości  $Y_t$  można lepiej prognozować na podstawie całego dostępnego zbioru informacji, niż używając informacji z wyłączeniem  $X_t$  (Osińska, 2008). Zmienna  $X_t$  jest więc przyczyną w sensie Grangera dla zmiennej  $Y_t$  (tzn.  $X_t \rightarrow Y_t$ ), jeśli

uwzględnienie w modelu objaśniającym  $Y_t$  opóźnionych wartości zmiennej  $X_t$  poprawia jakość prognozowania zmiennej  $Y_t$ .

Przed przeprowadzeniem testu Grangera poszczególne zmienne zostały poddane badaniu na występowanie pierwiastka jednostkowego w celu stwierdzenia stacjonarności szeregów. Posłużył temu rozszerzony test Dickeya-Fullera (ADF), szerzej opisany w pracy Maddali (Maddala, 2008). Hipoteza o stacjonarności zmiennych była rozstrzygana przy poziomie istotności 0,05.

Badanie przyczynowości w sensie Grangera zostało przeprowadzone z wykorzystaniem modelu VAR (por, np. (Charemza & Deadman, 1997), (Maddala, 2008))(10):

$$Y_t = A_0 D_t + \sum_{j=1}^k \alpha_j Y_{t-j} + \sum_{j=1}^k \beta_j X_{t-j} + \varepsilon_t \quad (10)$$

gdzie:

$A_0 D_t$  — deterministyczna część równania (wyraz wolny, trend deterministyczny, zmienne sezonowe),

$\alpha_j, \beta_j$  (dla  $j = 1, 2, \dots, k$ ) – parametry strukturalne równania,

$k$  — rząd opóźnień dla zmiennych  $X_t$  i  $Y_t$ ,

$\varepsilon_t$  — składnik losowy.

Sprawdzenie oddziaływania przyczynowego w sensie Grangera między zmiennymi odbywa się poprzez weryfikację zespoły hipotez, gdzie hipoteza  $H_0$  przyjmuje postać:  $\beta_1 = \beta_2 = \dots = \beta_k = 0$  oznacza, że zmienna  $X_t$  nie jest przyczyną  $Y_t$  w sensie Grangera. W pracy została ona zweryfikowana za pomocą statystyki Walda o rozkładzie  $\chi^2(k)$  przy poziomie istotności 0.05. Statystyka testowa z rozkładem  $\chi^2(k)$  jest wykorzystywana w przypadku dużych prób. Fałszywość tej hipotezy (odrzuć hipotezę zerową) świadczy o występowaniu przyczynowości. Maksymalny rząd opóźnień dla modeli VAR został wyznaczony arbitralnie na poziomie 7. Rząd opóźnień został ustalony na 7 ponieważ giełda kryptowalut funkcjonuje cały tydzień, także w dni weekendowe. W niniejszej pracy analiza przyczynowości została dokonana dla trzech par zmiennych:  $P_t$  i  $V_t$ ,  $R_t$  i  $V_t$  oraz  $D_t$  i  $V_t$ , na podstawie następujących modeli (11):

$$\begin{cases}
P_t = \alpha_1 + \sum_{j=1}^7 b_{1j}P_{t-j} + \sum_{j=1}^7 c_{1j}V_{t-j} + \varepsilon_{1t} \\
V_t = \alpha_2 + \sum_{j=1}^7 b_{2j}P_{t-j} + \sum_{j=1}^7 c_{2j}V_{t-j} + \varepsilon_{2t} \\
R_t = \alpha_3 + \sum_{j=1}^7 b_{3j}R_{t-j} + \sum_{j=1}^7 c_{3j}V_{t-j} + \varepsilon_{3t} \\
V_t = \alpha_4 + \sum_{j=1}^7 b_{4j}R_{t-j} + \sum_{j=1}^7 c_{4j}V_{t-j} + \varepsilon_{4t} \\
D_t = \alpha_5 + \sum_{j=1}^7 b_{5j}D_{t-j} + \sum_{j=1}^7 c_{5j}V_{t-j} + \varepsilon_{5t} \\
V_t = \alpha_6 + \sum_{j=1}^7 b_{6j}R_{t-j} + \sum_{j=1}^7 c_{6j}V_{t-j} + \varepsilon_{6t}
\end{cases} \quad (11)$$

Sposób przeprowadzenia testu został przedstawiony w książce Charemzy i Deadmana (Charemza & Deadman, 1997). Dodatkowo badanie przyczynowości zostało poprzedzone testami kointegracji Johansena, dla których  $H_0$  oznacza brak występowania kointegracji. Informują one o potencjalnym istnieniu długookresowego związku między zmiennymi (kointegracja implikuje przyczynowość w sensie Grangera) (Widz, 2017).

### 3. Wyniki empiryczne

W tym rozdziale zostały przedstawione wyniki z przeprowadzonych badań empirycznych. Do przeprowadzenia analizy występowania efektu dnia tygodnia został użyty program Gretl, z kolei analizę zdarzeń i analizę wolumenu obrotów przeprowadzono przy wykorzystaniu odpowiednich bibliotek w Pythonie. Wykorzystane w badaniach empirycznych dane statystyczne pochodzą z Yahoo Finance. Baza danych o częstotliwości dziennej z okresu pięciu lat, od 1.01.2018 do 31.12.2022. Liczebność próby wynosi 1826 obserwacji. Kryptowaluty brane pod uwagę w pracy (BTC - Bitcoin, BNB - Binance Coin, XMR - Monero, BAT - Basic Attention Token) zostały przedstawione w stosunku do dolara amerykańskiego USD.

#### 3.1. Efekt dnia tygodnia

W pierwszym kroku wartości analizowanych zmiennych zostały przekształcone do postaci logarytmicznych dziennych stóp zwrotu, wyznaczonych na podstawie wzoru  $r_t = 100 * \ln\left(\frac{P_t}{P_{t-1}}\right)$ , gdzie  $P_t$  oznacza poziom kurs zamknięcia dla analizowanej kryptowaluty (w USD) w momencie  $t$ .

Następnie obliczoneienne stopy zwrotu pogrupowano w zależności od dnia tygodnia, w którym przypadły. Dla wybranych kryptowalut wyznaczono wartości przeciętne, zarówno dla całego rozpatrywanego okresu (Tabela 1), jak i dla rocznych podokresów (Tabela 2).

		Wszystkie dni	Poniedziałki	Wtorki	Środy	Czwartki	Piątki	Soboty	Niedziele
BTC	średnia arytm.	0.01	0.14	-0.12	0.18	-0.34*	0.17	0.20	-0.16
	odch. stand.	3.90	4.43	3.91	4.07	5.01	3.68	2.62	3.12
	wsp. zmienn.	371.04	31.99	-31.98	22.82	-14.84	21.11	13.01	-19.60
	skośność	-1.07	-0.12	-0.55	-0.35	-2.97	0.30	0.16	-0.52
	kurtoza	13.25	2.70	3.59	2.19	27.73	2.00	4.62	2.94
BNB	średnia arytm.	0.19	-0.11	0.20	0.22	-0.24	0.96	0.48	-0.22
	odch. stand.	5.70	5.80	6.17	5.84	6.24	6.55	4.57	4.33
	wsp. zmienn.	30.82	-53.31	31.14	26.18	-26.03	6.85	9.50	-19.86
	skośność	0.26	-0.02	0.08	-1.17	-2.38	3.39	2.12	-0.44
	kurtoza	16.58	4.02	6.88	10.05	21.85	24.80	30.38	4.24
XMR	średnia arytm.	-0.05	-0.39	-0.43	-0.02	-0.49*	0.28	0.34	0.37
	odch. stand.	5.36	5.66	5.24	6.26	6.64	4.74	3.97	4.43
	wsp. zmienn.	-109.72	-14.69	-12.16	-283.03	-13.42	16.91	11.53	12.03
	skośność	-1.07	-0.96	-0.36	-2.49	-1.04	0.04	0.10	0.26
	kurtoza	11.84	3.13	5.18	20.39	13.59	0.59	3.23	3.12
BAT	średnia arytm.	-0.06	-0.33	-0.32	-0.08	-0.47*	1.15	0.47	-0.82*
	odch. stand.	6.40	6.26	6.55	7.27	7.15	6.48	5.52	5.15
	wsp. zmienn.	-111.05	-18.69	-20.69	-89.74	-15.14	5.64	11.76	-6.27
	skośność	-0.13	0.13	-0.41	-0.23	-1.18	0.55	1.65	-0.59
	kurtoza	5.91	2.71	4.80	4.23	10.51	2.23	9.96	2.36

*Tabela 1. Charakterystyki dla dziennych stóp zwrotu wybranych kryptowalut wraz z wartościami podstawowych statystyk opisowych w okresie od 1.01.2018 do 31.12.2022 dla całej próby oraz w zależności od dnia tygodnia*

*Źródło: opracowanie własne*

Dla wszystkich badanych kryptowalut przeciętne piątkowe oraz sobotnie stopy zwrotu były w łącznym badanym okresie dodatnie i znacznie wyższe od uzyskiwanych w inne dni tygodnia. Na uwagę zasługują zazwyczaj ujemne czwartkowe stopy. Najwyższe odchylenia standardowe dla zwrotów z kryptowalut zanotowano w czwartki, najniższe – w soboty. Jak wynika z danych, analizowane rozkłady stóp zwrotu charakteryzują się wysoką zmiennością, zwykle lewostronną skośnością oraz zawsze podwyższoną kurtozą. Należy zwrócić szczególną uwagę na BTC i BNB, dla których kurtoza jest szczególnie wysoka, co może sugerować występowanie ekstremalnych zdarzeń w badanych okresie. Są to cechy towarzyszące zazwyczaj finansowym szeregom czasowym. W (Tabela 1) jako \* oznaczono wartości średnie, które są istotnie mniejsze od 0 (na poziomie istotności 0,05).

		Wszystkie dni	Poniedziałki	Wtorki	Środy	Czwartki	Piątki	Soboty	Niedziele
BTC	2018	-0.36	-0.72	-0.47	-0.90	-0.33	-0.07	0.42	-0.42
	2019	0.18	0.52	-0.31	0.50	-0.88	1.01	0.43	-0.01
	2020	0.38	1.14	0.60	0.86	-0.10	0.27	0.25	-0.37
	2021	0.13	-0.17	-0.31	0.75	-0.11	0.36	0.09	0.29
	2022	-0.28	-0.08	-0.11	-0.33	-0.27	-0.71	-0.18	-0.29
BNB	2018	-0.09	-1.11	-0.33	-0.54	-0.21	2.08	1.05	-1.54
	2019	0.22	0.01	-0.33	0.58	-0.47	1.26	0.80	-0.31
	2020	0.27	0.88	0.51	0.01	-0.93	0.71	0.63	0.13
	2021	0.72	0.51	0.61	1.55	0.52	1.08	0.06	0.69
	2022	-0.20	-0.84	0.54	-0.48	-0.10	-0.36	-0.12	-0.06
XMR	2018	-0.56	-1.51	-1.07	-1.03	-1.06	0.35	0.20	0.18
	2019	-0.01	0.09	-1.06	0.91	-1.67	1.09	0.25	0.35
	2020	0.34	0.99	0.46	0.23	-0.12	0.32	0.53	0.01
	2021	0.10	-1.30	-0.23	0.07	0.42	0.05	0.65	1.07
	2022	-0.12	-0.20	-0.24	-0.29	-0.05	-0.41	0.10	0.24
BAT	2018	-0.36	-0.95	-1.22	-0.72	-0.60	1.00	0.80	-0.82
	2019	0.10	-0.67	-0.64	0.06	-1.03	2.42	1.19	-0.66
	2020	0.03	0.86	0.54	-0.46	-1.13	1.46	0.13	-1.18
	2021	0.49	-0.08	-0.46	1.50	0.47	1.94	0.54	-0.49
	2022	-0.54	-0.83	0.21	-0.78	-0.07	-1.09	-0.30	-0.96

Tabela 2. Przeciętne dzienne stopy zwrotu dla kryptowalut w rozbiciu na roczne podokresy

Źródło: opracowanie własne

Analizując roczne podokresy (Tabela 2) można zauważyć wyraźną różnicę występującą pomiędzy rokiem 2018 a latami 2019-2022. Różnica ta dotyczy ujemnych stóp zwrotu w roku 2018, wszystkie badane kryptowaluty zanotowały ujemne dzienne stopy zwrotu, co oznacza spadek cen w ciągu całego roku. Z uwagi na zakres czasowy badania nie można stwierdzić, czy zaobserwowane zależności mają charakter trwały, czy też są dziełem przypadku.

Przed przystąpieniem do modelowania wariancji stóp zwrotu przeprowadzono badanie ciągu logarytmicznych stóp zwrotu  $r_t$  pod kątem jego stacjonarności, występowania autokorelacji oraz obecności efektu ARCH. Stacjonarność badano za pomocą testu Dickeya-Fullera w wersji rozszerzonej (ADF), uzyskując każdorazowo pozytywny wynik (wszystkie analizowane szeregi okazały się niestacjonarne, zintegrowane w stopniu pierwszym). Występowanie autokorelacji badano za pomocą testu Boxa-Pierce'a, nie stwierdzono jednak jej występowania w resztach modelu bazowego.

Następnie estymowano parametry poszczególnych modeli: model liniowy ze zmiennymi binarnymi reprezentującymi efekt dnia tygodnia (1), oraz zmodyfikowany model GARCH z uwzględnioną sezonowością (periodycznością) w równaniu średniej i wariancji (4). Dokonując wyboru rzędu opóźnień w strukturze  $GARCH(q, p)$  kierowano się istotnością parametrów strukturalnych, wartościami kryteriów informacyjnych Akaike’a (AIC) i Schwarza (BIC) oraz wielkością ujemnego dwukrotnego logarytmu funkcji wiarygodności ( $-2\ln L$ ), który jest tym mniejszy, im większa jest wiarygodność wyników.

Wyniki estymacji przedstawia (Tabela 3). Oceny parametrów z oszacowanego równania (1) (w tabelach w kolumnach o nagłówku MRL (model regresji liniowej) – model regresji liniowej uwzględniający efekt dnia tygodnia) wskazują na średnią stopę zwrotu dla każdego z dni tygodnia. Stopy zwrotu z piątku okazywały się statystycznie istotnie różne od zera dla BNB, a dla BAT w piątek i niedzielę. Warto tutaj zwrócić uwagę na fakt, że reszty modeli (1) nie charakteryzowała autokorelacja składnika losowego.

Wprowadzenie do modeli równania dla wariancji warunkowej spowodowało polepszenie ich jakości. Estymatory są teraz bardziej efektywne (uzyskano mniejsze błędy ocen odpowiednich parametrów). Zmniejszeniu uległy wartości  $-2\ln L$ . Parametry w równaniach na wariancję uzyskały dodatnie oceny, ich sumy (poza stałymi) są mniejsze niż 1, aczkolwiek zbliżone do tej wartości. Ten ostatni fakt wskazuje na to, że informacje z odległej przeszłości są istotne w wyjaśnieniu bieżącej zmienności (*persistence of volatility*).

W zmodyfikowanych modelach GARCH typu (4) efekt dnia tygodnia jest obecny w obu równaniach: w wyraźny sposób w równaniach na średnią i w słabszy w równaniach na wariancję warunkową. W równaniach średniej statystycznie inny okazał się piątek dla BNB, z kolei dla BAT piątek jak i niedziela. Jeśli zaś chodzi o wariancję warunkową, to statystycznie istotna okazała się tylko dla BNB w piątki.



	BTC		BNB		XMR		BAT	
	MRL	GARCH (2,2)	MRL	GARCH (2,2)	MRL	GARCH (2,2)	MRL	GARCH (2,2)
Poniedziałek	0,139 [0.567]	0.153 [0.470]	-0.109 [0.758]	0.297 [0.249]	-0.385 [0.246]	0.461 [0.089]	-0.335 [0.398]	0.087 [0.795]
Wtorek	-0,122 [0.613]	0.067 [0.753]	0.198 [0.574]	-0.224 [0.382]	-0.431 [0.193]	0.154 [0.579]	-0.316 [0.423]	-0.207 [0.529]
Środa	0,178 [0.461]	-0.049 [0.818]	0.223 [0.527]	-0.339 [0.183]	-0.02 [0.947]	0.317 [0.252]	-0.081 [0.838]	-0.017 [0.958]
Czwartek	-0,338 [0.163]	-0.018 [0.933]	-0.240 [0.497]	0.053 [0.836]	-0.495 [0.136]	0.169 [0.527]	-0.472 [0.232]	0.015 [0.964]
Piątek	0,174 [0.471]	-0.458 [0.823]	<b>0.957</b> <b>[0.007]</b>	<b>-0.534</b> <b>[0.039]</b>	0.280 [0.398]	-0.031 [0.910]	<b>1.149</b> <b>[0.004]</b>	-0.158 [0.632]
Sobota	0,201 [0.405]	0.033 [0.881]	0.481 [0.173]	0.218 [0.428]	0.344 [0.299]	0.224 [0.429]	0.470 [0.235]	0.181 [0.591]
Niedziela	-0,159 [0.511]	0.342 [0.114]	-0.218 [0.538]	0.098 [0.721]	0.368 [0.268]	0.100 [0.721]	<b>-0.822</b> <b>[0.038]</b>	0.266 [0.420]
Alpha(0)		<b>2,072</b> <b>[7.19E-09]</b>		<b>3.117</b> <b>[9.74E-07]</b>		<b>2.776</b> <b>[8.63E-06]</b>		<b>4.429</b> <b>[4.81E-05]</b>
Alpha(1)		<b>0.057</b> <b>[0.002]</b>		<b>0.090</b> <b>[2.15E-05]</b>		<b>0.062</b> <b>[0.002]</b>		<b>0.096</b> <b>[3.20E-06]</b>
Alpha(2)		<b>0.148</b> <b>[1.59E-08]</b>		<b>0.264</b> <b>[1.79E-010]</b>		<b>0.187</b> <b>[5.29E-010]</b>		<b>0.177</b> <b>[2.60E-08]</b>
Beta(1)		0.005 [0.928]		0.078 [0.180]		0.076 [0.237]		0.042 [0.534]
Beta(2)		<b>0.671</b> <b>[3.45E-033]</b>		<b>0.508</b> <b>[5.03E-016]</b>		<b>0.598</b> <b>[2.52E-022]</b>		<b>0.598</b> <b>[2.19E-015]</b>
R2	0.002584		0.004901		0.004462		0.009193	
DW	2.092171		2.079713		2.279257		2.177867	
-2lnL	10143.674	9972.394	11522.952	10980.62	11295.674	10989.194	11937.156	11669.564
AIC		9998.395		11006.62		11015.19		11695.56
SIC		10070.02		11078.24		11086.81		11767.18

Tabela 3. Wyniki estymacji modeli regresji

Źródło: opracowanie własne

### 3.2. Analiza zdarzeń

W niniejszej pracy do obliczeń rzeczywistej stopy zwrotu wykorzystano model oparty na średniej stopie zwrotu z okresu niezależnego. Średnie stopy zwrotu obliczono dla składników alternatywnych i klasycznych korzystając ze wzoru (6). Składniki klasyczne to wybrane indeksy giełdowe:

- S&P 500 – indeks giełdowy, w skład którego wchodzi 500 przedsiębiorstw o największej kapitalizacji, notowanych na New York Stock Exchange i NASDAQ,
- FTSE 250 – indeks giełdowy na londyńskiej giełdzie, skupiający największe spółki pod względem kapitalizacji od 101 do 350,
- DAX – niemiecki indeks giełdowy największych pod względem udziału w obrotach i kapitalizacji spółek na giełdzie we Frankfurcie,
- WIG – Warszawski Indeks Giełdowy – jest indeksem giełdowym o otwartym funduszu, co oznacza, że każdy może kupować i sprzedawać indeks jak akcje.

Indeks WIG jest publikowany codziennie przez GPW i jest uważany za ważny wskaźnik kondycji gospodarki polskiej.

Jako składniki alternatywne zostały przyjęte kryptowaluty analizowane w prezentowanym badaniu.

Analizę zdarzeń przedstawiono na podstawie reakcji poszczególnych składników w konsekwencji wybuchu wojny Ukrainy z Rosją z dnia 24.02.2022, w wyniku której zginęło ponad 280 tys. osób. Wydarzenie to miało charakter globalny, które wywołało chaos na rynkach, szczególnie wzrost ropy Brent i najwyższą cenę pszenicy od 2008 roku. Rzeczywiste stopy obliczono na podstawie dziennych stóp zwrotu z 30 poprzednich dni, tj. od 22.01.2022 do 21.02.2022 roku, tworząc tzw. okno estymacji. Ponieważ Rosja zbierała wojska przy granicy z Ukrainą już od wielu dni przed tym zdarzeniem, a informacje te były ogólnodostępne, gdy sytuacja stawała się co raz bardziej napięta inwestorzy także reagowali na te zmiany, dlatego też okno zdarzenia zaczyna się dwa dni przed wydarzeniem. Z kolei kończy 5 dni po nim, ponieważ w trakcie miał miejsce weekend, kiedy giełdy tradycyjne są zamknięte, dlatego też, aby pokazać, jakie nastroje na giełdzie będą po weekendzie, okno zostało wydłużone.

Dzień $t$	Składniki klasyczne				Składniki alternatywne				
	S&P 500	FTSE	DAX	WIG	BTC	BNB	XMR	BAT	
	AR (%)								
Okno zdarzenia	-2	-0.96	-0.23	0.03	1.63	3.16	5.02	2.54	6.05
	-1	-1.81	-0.46	-0.14	-2.06	-2.65	-1.81	-0.60	-3.07
	0	1.54	-2.63	-3.84	-11.60	2.70	-1.16	-0.82	1.14
	1	2.25	3.38	3.82	7.58	2.25	3.96	4.79	6.92
	2	-	-	-	-	-0.28	-0.03	3.25	0.69
	3	-	-	-	-	-3.70	-3.33	-4.00	-4.16
	4	-0.18	1.09	-0.45	1.61	12.69	9.17	12.03	10.43
	5	-1.51	-2.57	-3.71	-1.43	2.62	3.46	4.73	2.82
CAR	-0.66	-1.42	-4.29	-4.26	16.79	15.27	21.92	20.82	
ACAR	-2.66	18.7							

*Tabela 4. Wybuch wojny między Rosją a Ukrainą 2022-02-24*

*Źródło: opracowanie własne*

W (Tabela 4) zaprezentowanoienne nadwyżkowe stopy zwrotu dla poszczególnych składników inwestycyjnych. Indeks WIG odnotował dzienną nadwyżkową stopę zwrotu dla  $D_{-2}$  w wysokości 1.63%, co oznacza, że dzień przed zamachem wartość indeksu na koniec dnia była o 1.63% wyższa niż w dniu poprzedzającym. W dniu wybuchu wojny wartość AR wyniosła -11.60%, natomiast dzień

po już 7.58%. Skumulowana stopa zwrotu (CAR) dla WIG wyniosła -4.26%. Oznacza to, że w wyniku wybuchu wojny na Ukrainie, indeks stracił na wartości w analizowanym okresie 4.26%. Analogiczne obliczenia wykonano dla wszystkich składników klasycznych i alternatywnych. Dodatkowo dokonano również obliczenia wartości ACAR – oddzielnie dla inwestycji klasycznych i alternatywnych. W wyniku przeprowadzonych badań można stwierdzić, że w konsekwencji wybuchu wojny na Ukrainie, wartość ACAR dla składników klasycznych wyniosła -2.66%. Z kolei składniki alternatywne odnotowały wzrost wartości o 18.7%. Oznacza to, iż w wyniku tego wydarzenia – składniki alternatywne okazały się lepszym wyborem do ulokowania swoich środków.

### 3.3. Analiza wolumenu obrotów

Wybrane statystyki opisowe dla poszczególnych zmiennych w przyjętym okresie badawczym przedstawiono w (Tabela 5). Szereg stóp zwrotu dla BNB cechował się najwyższą średnią, ale największą zmienność stóp zwrotu zanotowano dla BTC. Z kolei największa zmienność wolumenu obrotu charakteryzowała BAT.

Zmienna	Średnia	Mediana	Odchylenie standardowe	Współczynnik zmienności	Skośność	Kurtoza
P_BTC	20338.67	10960.59	16986.02	83.52	1.03	-0.29
P_BNB	150.99	27.46	183.83	121.75	0.97	-0.43
P_XMR	146.42	129.86	85.24	58.22	0.97	0.64
P_BAT	0.41	0.28	0.30	73.81	1.61	1.98
R_BTC	1.05E-04	9.76E-04	0.04	37104.01	-1.07	13.25
R_BNB	1.85E-03	6.58E-04	0.06	3081.52	0.26	16.58
R_XMR	-4.88E-04	2.03E-03	0.05	-10972.03	-1.07	11.84
R_BAT	-5.76E-04	-6.86E-04	0.06	-11105.24	-0.13	5.91
V_BTC	2.66E+10	2.43E+10	1.98E+10	74.53	3.30	40.20
V_BNB	9.93E+08	3.85E+08	1.45E+09	145.77	3.46	20.65
V_XMR	2.72E+08	1.14E+08	1.08E+09	398.67	21.91	531.07
V_BAT	1.30E+08	6.49+07	2.18E+08	167.53	6.53	69.24

Tabela 5. Wybrane statystyki dla całej próby

Źródło: opracowanie własne

Uwagi: P – cena zamknięcia, R – stopa zwrotu, V – wolumen

Badanie zależności korelacyjnych między zmiennymi w całym okresie badawczym wykazało umiarkowaną korelację ceny zamknięcia z wolumenem obrotu dla BTC i BAT, silną dla BNB i znikomą dla XMR, umiarkowaną lub znikomą korelację zmienności stóp zwrotu z wolumenem obrotu dla wszystkich kryptowalut, a także praktycznie brak korelacji stóp zwrotu z wolumenem obrotu.

W prawie wszystkich podokresach korelacja ceny do wolumenu była silna bądź umiarkowana dla wszystkich kryptowalut ze zwróceniem szczególnej uwagi na okresy III, IV i VI.

Kryptowaluta	I okres	II okres	III okres	IV okres	V okres	VI okres	Cały okres
BTC	0.78	0.86	0.07	0.55	0.60	0.00	0.55
BNB	0.62	0.93	0.34	0.82	0.57	0.57	0.71
XMR	0.80	0.67	0.06	0.1	0.65	0.67	0.05
BAT	0.61	0.85	0.39	0.67	0.85	0.61	0.61

*Tabela 6. Współczynniki korelacji ceny zamknięcia z wolumenem obrotu*

*Źródło: opracowanie własne*

Dla korelacji stóp zwrotu i wolumenu tylko BNB w okresie IV przekroczyła próg 0.3 tym samym korelacja była słaba lub nie występowała

Kryptowaluta	I okres	II okres	III okres	IV okres	V okres	VI okres	Cały okres
BTC	-0.01	0.18	0.04	0.02	-0.19	-0.2	0.00
BNB	0.30	0.08	0.22	0.31	-0.09	-0.11	0.08
XMR	0.08	-0.01	0.03	0.04	0.05	-0.03	0.03
BAT	0.18	0.15	0.10	0.29	-0.11	0.19	0.16

*Tabela 7. Współczynniki korelacji stóp zwrotu z wolumenem obrotu*

*Źródło: opracowanie własne*

Między zmiennością stóp zwrotu a wolumenem korelacja wystąpiła głównie w I okresie, gdzie w pozostałych utrzymywała się na niskim bądź umiarkowanym poziomie

Kryptowaluta	I okres	II okres	III okres	IV okres	V okres	VI okres	Cały okres
BTC	0.69	0.33	-0.07	0.31	-0.07	0.11	0.19
BNB	0.43	-0.21	0.22	0.57	0.24	0.20	0.34
XMR	0.53	-0.28	-0.09	0.05	-0.06	0.32	0.03
BAT	0.15	0.37	-0.29	0.29	-0.10	0.48	0.25

*Tabela 8. Współczynniki korelacji zmienności stóp zwrotu z wolumenem obrotu*

*Źródło: opracowanie własne*

Kryterium oceny siły korelacji opiera się na fragmencie książki (Ostasiewicz, et al., 1998)

Wartości zmiennej p-value dla testu Dickeya-Fullera, mówiącej o możliwości przyjęcia bądź odrzucenia hipotezy zerowej o występowaniu pierwiastka jednostkowego, zostały zamieszczone w (Tabela 5) (dla całego okresu badawczego). Stacjonarne okazały się zarówno szeregi stóp zwrotów badanych kryptowalut, ich zmienności, jak i szeregi wolumenów obrotu dla BNB i XMR.

Zmienna	Statystyka	p-value
P_BTC	-1.3681	0.60
P_BNB	-1.5761	0.50
P_XMR	-2.6506	0.08
P_BAT	-2.0088	0.28
<b>R_BTC</b>	<b>-29.6726</b>	<b>0.00E+00</b>
<b>R_BNB</b>	<b>-12.8216</b>	<b>6.14E-24</b>
<b>R_XMR</b>	<b>-20.5069</b>	<b>0.00E+00</b>
<b>R_BAT</b>	<b>-30.8062</b>	<b>0.00E+00</b>
<b>D_BTC</b>	<b>-4.9159</b>	<b>3.25E-05</b>
<b>D_BNB</b>	<b>-4.8356</b>	<b>4.65E-05</b>
<b>D_XMR</b>	<b>-4.815</b>	<b>5.09E-05</b>
<b>D_BAT</b>	<b>-4.7114</b>	<b>8.01E-05</b>
V_BTC	-2.8188	0.06
<b>V_BNB</b>	<b>-3.2637</b>	<b>0.02</b>
<b>V_XMR</b>	<b>-7.0819</b>	<b>4.64E-10</b>
V_BAT	-2.4693	0.12

Tabela 9. Wyniki testu ADF dla całego okresu

Źródło: opracowanie własne

Stopy zwrotu okazały się stacjonarne w każdym okresie, dla każdej kryptowaluty, wolumen obrotu w okresie I, a zmienność stóp zwrotu w okresie VI.

Zmienna	I okres	II okres	III okres	IV okres	V okres	VI okres
P_BTC			Y			
P_BNB						
P_XMR						Y
P_BAT	Y					
R_BTC	Y	Y	Y	Y	Y	Y
R_BNB	Y	Y	Y	Y	Y	Y
R_XMR	Y	Y	Y	Y	Y	Y
R_BAT	Y	Y	Y	Y	Y	Y
D_BTC				Y		Y
D_BNB	Y		Y	Y		Y
D_XMR				Y		
D_BAT	Y		Y			Y
V_BTC	Y					Y
V_BNB	Y		Y			
V_XMR	Y			Y		
V_BAT	Y					Y

Tabela 10. Wyniki testu ADF dla poszczególnych podokresów

Źródło: opracowanie własne

Uwagi: Y – oznacza występowanie pierwiastka jednostkowego

Analiza wyników badania kointegracji: testu śladu i testu Lmax pozwoliła stwierdzić brak występowania kointegracji tylko w dwóch przypadkach, dla ceny zamknięcia i wolumenu obrotu dla BTC i BNB o rzędzie 1 (Tabela 11):

Zmienne	Rząd	Wartość własna	Test śladu	Test Lmax
P_BTC i V_BTC	0	0.077	<b>148.415</b>	146.895
	1	0.01	1.519	1.519
P_BNB i V_BNB	0	0.063	<b>120.141</b>	118.249
	1	0.001	1.892	1.892
P_XMR i V_XMR	0	0.157	<b>322.005</b>	312.449
	1	0.005	9.557	9.557
P_BAT i V_BAT	0	0.184	<b>376.685</b>	370.798
	1	0.003	5.887	5.887

Tabela 11. Wyniki testu Johansena

Źródło: opracowanie własne

Z (Tabela 12) wynika, że XMR wykazuje przyczynowość w sensie Grangera dla pozostałych kryptowalut, natomiast BNB dla wszystkich poza XMR.

Kierunek oddziaływania	Statystyka $\chi^2$	p-value	Przyczynowość
R_BTC→R_BNB	6.02	0.538	
R_BTC→R_XMR	6.94	0.4348	
R_BTC→R_BAT	13.05	0.0708	
R_BNB→R_BTC	18.34	0.0105	Y
R_BNB→R_XMR	11.45	0.12	
R_BNB→R_BAT	24.00	1.14E-03	Y
R_XMR→R_BTC	17.20	0.0161	Y
R_XMR→R_BNB	17.67	0.0135	Y
R_BAT→R_BAT	16.18	0.0235	Y
R_BAT→R_BTC	3.66	0.8175	
R_BAT→R_BNB	3.68	0.8163	
R_BAT→R_XMR	11.99	0.1008	

Tabela 12. Test przyczynowości w sensie Grangera dla stóp zwrotu

Źródło: opracowanie własne

Test nie dał natomiast podstaw do stwierdzenia istnienia przyczynowości w przeciwnym kierunku: wolumen nie jest przyczyną w sensie Grangera, dla stóp zwrotu jest on natomiast przyczyną w sensie Grangera dla zmienności stóp zwrotu.

	Kierunek oddziaływania	Statystyka $\chi^2$	p-value	Przyczynowość
BTC	P→V	44.72	1.55E-07	Y
	V→P	31.09	5.98E-05	Y
	R→V	20.76	4.14E-03	Y
	V→R	6.21	0.5151	
	D→V	32.22	3.70E-05	Y
	V→D	12.25	0.0926	
BNB	P→V	26.98	3.36E-04	Y
	V→P	79.44	1.79E-04	Y
	R→V	10.70	0.1521	
	V→R	37.48	3.81E-06	Y
	D→V	13.17	0.068	
	V→D	26.43	4.22E-04	Y
XMR	P→V	1.85	0.9677	
	V→P	1.70	0.9745	
	R→V	3.98	0.7823	
	V→R	2.82	0.9015	
	D→V	1.72	0.9739	
	V→D	1.65	0.9766	
BAT	P→V	91.24	6.90E-17	Y
	V→P	48.49	2.86E-08	Y
	R→V	25.41	6.43E-04	Y
	V→R	8.83	0.2654	
	D→V	41.04	0.7.96E-07	Y
	V→D	18.16	0.0113	Y

Tabela 13. Test przyczynowości w sensie Grangera dla całego okresu badawczego

Źródło: opracowanie własne

Kierunek oddziaływania		Przyczynowość					
		I okres	II okres	III okres	IV okres	V okres	VI okres
BTC	$P \rightarrow V$		Y		Y		
	$V \rightarrow P$		Y		Y		
	$R \rightarrow V$		Y		Y		
	$V \rightarrow R$		Y		Y		
	$D \rightarrow V$	Y		Y			
	$V \rightarrow D$	Y		Y			
BNB	$P \rightarrow V$		Y		Y		Y
	$V \rightarrow P$		Y		Y		Y
	$R \rightarrow V$	Y			Y		
	$V \rightarrow R$	Y			Y		
	$D \rightarrow V$						
	$V \rightarrow D$						
XMR	$P \rightarrow V$	Y	Y				Y
	$V \rightarrow P$	Y	Y				Y
	$R \rightarrow V$	Y	Y				
	$V \rightarrow R$	Y	Y				
	$D \rightarrow V$						
	$V \rightarrow D$						
BAT	$P \rightarrow V$		Y		Y	Y	Y
	$V \rightarrow P$		Y		Y	Y	Y
	$R \rightarrow V$						Y
	$V \rightarrow R$						Y
	$D \rightarrow V$			Y			Y
	$V \rightarrow D$			Y			Y

Tabela 14. Test przyczynowości w sensie Grangera dla poszczególnych podokresów badawczych

Źródło: opracowanie własne



## 4. Wnioski

Ze wstępnej analizy statystycznej wynika, że przeciętne stopy zwrotu dla trzech kryptowalut są bliskie zeru, natomiast najwyższą osiąga dla BNB i wynosi ona 0.19. Sytuacja diametralnie się zmienia, kiedy podzielimy zbiór na różne dni tygodnia. Jak wynika z danych, najwyższe wartości dodatnie osiągają piątkowe i sobotnie stopy zwrotu. Można również zauważyć, że zmienność jest bardzo wysoka, a kurtoza jest podwyższona. Należy zwrócić uwagę na kryptowaluty BTC i BNB, dla których wartość kurtozy jest szczególnie wysoka. Może to sugerować występowanie ekstremalnych zdarzeń w badanym okresie. W kolejnym kroku estymowano parametry regresji liniowej, gdzie efekt dnia tygodnia był reprezentowany przez zmienne zero-jedynkowe. Oszacowane wartości parametrów wskazały, że tylko w nielicznych przypadkach obserwowano efekt dnia tygodnia. Taka sytuacja wystąpiła w przypadku kryptowaluty BNB i piątkowych stóp zwrotu oraz kryptowaluty BAT i stóp zwrotu z piątku i niedzieli. Może to wskazywać na istnienie periodyczności lub określonych wzorców handlu dla niektórych kryptowalut. Dla walut, które są utożsamiane jako bardziej płynne (o większej liczbie transakcji), nie zaobserwowano efektu dnia tygodnia, co może wskazywać na więcej symptomów przemawiających za efektywnością informacyjną. Wprowadzenie do modelu dodatkowego równania opisującego wariancję warunkową poprawiło jakość estymatorów. Z reguły, w równaniu wariancji warunkowej nie wykryto efektu dnia tygodnia. Jedynym odstępstwem jest kryptowaluta BNB i parametr w modelu GARCH przy piątkowych stopach zwrotu. W tym przypadku analiza wskazała, że wpływ dnia tygodnia jest obecny w obu równaniach, zarówno w równaniu średniej jak i równaniu wariancji warunkowej.

Reakcja inwestorów w sytuacjach nadzwyczajnych, takich jak wydarzenia polityczne, gospodarcze czy też terrorystyczne mogą być zupełnie różne. W prezentowanej analizie sprawdzano wpływ na rynek kryptowalut, wybuchu wojny na Ukrainie. Dodatkowo sprawdzono wpływ tego wydarzenia na zachowanie inwestorów na rynkach klasycznych. Wyniki badania wskazują, że w tym okresie inwestorzy inwestujący w aktywa klasyczne cechuje większa podatność do wpadania w pułapkę „przynależności do tłumu”. Oznacza to, że podejmują decyzje razem z „tłumem” (jak większość inwestorów), w efekcie czego ich zachowania prowadzą do wyprzedzaży i paniki na rynkach finansowych. Inwestorzy inwestujący w aktywa alternatywne

natomiast cechują się mniejszą podatnością na informacje dobiegające z zewnątrz, w konsekwencji czego same składniki alternatywne mniej tracą (a nawet zyskują) na wartości, gdyż ich wyprzedaż nie jest tak liczna (pod względem wolumenu, jak i liczby transakcji) jak w przypadku instrumentów klasycznych. W przypadku kryptowalut również zaobserwowano taką tendencję, czyli duży napływ chętnych inwestorów, co skutkuje zwiększonym ruchem na rynku kryptowalut. Jak można było się spodziewać, spośród analizowanych klasycznych inwestycji największe spadki osiągnięto na GPW w Warszawie, ponieważ jest położona w kraju sąsiadującym ze stroną konfliktu.

W przypadku analizy wolumenu obrotów w pierwszym kroku zaleca się przeprowadzenia badania korelacji. Analiza korelacji pokazała umiarkowaną zależność między ceną wolumenem obrotu a ceną zamknięcia (por. Tabela 6) dla BTC i BAT, silną dla BNB, oraz znikomą dla XMR. Z kolei korelacja między zmiennością stóp zwrotu a wolumenem obrotu była umiarkowana lub niewielka dla wszystkich kryptowalut, a korelacja między stopami zwrotu a wolumenem obrotu była znikoma. W większości badanych okresów czasowych zaobserwowano silną lub umiarkowaną zależność między ceną a wolumenem obrotu dla wszystkich kryptowalut. Otrzymane wyniki testu przyczynowości Grangera pokazały, że zmiany w szeregach powiązanych z kryptowalutą XMR, są przyczyną zmian w szeregach powiązanych z pozostałymi kryptowalutami. Natomiast w przypadku zmian w szeregach powiązanych z kryptowalutą BNB, są one przyczyną zmian w szeregach powiązanych z kryptowalutami BTC i BAT. Ponadto, wyniki testu wykazały, że wolumen obrotu nie przyczynia się do zmian w cenach, ale przyczynia się do kształtowania się zmienności stóp zwrotu. Oznacza to, że wysoki wolumen handlu niekoniecznie przekłada się na zmiany cen, ale wpływa na zmienność stóp zwrotu.

# Podsumowanie

Kryptowaluty stają się coraz bardziej popularnymi instrumentami finansowymi, które stanowią nie tylko formę inwestycji ale przede wszystkim alternatywę dla tradycyjnych metod płatności, których podstawowymi zaletami są brak regulacji i anonimizacja transakcji. Szczególnie w dzisiejszych czasach kryptowaluty mogą okazać się bardzo przydatne, ponieważ państwa mają tendencję do przechodzenia na model bezgotówkowy, aby mieć większą kontrolę nad swoimi obywatelami, co jest uznawane za ograniczanie wolności fiskalnej. Kryptowaluty oferują możliwość, aby uchronić się przed inwigilacją, co wskazuje na istotność przeprowadzonych badań.

Celem niniejszej pracy było sprawdzenie, czy pewne zjawiska występujące na giełdach tradycyjnych, występują także na rynkach kryptowalut. Do tych zjawisk zaliczono: analizę dnia tygodnia, analizę zdarzeń i analizę wolumenu obrotów.

W wyniku przeprowadzonych obliczeń w zakresie podstawowych statystyk stwierdzono, że piątki i soboty charakteryzowały się dodatnimi i wyższymi stopami zwrotu niż pozostałe dni. Czwartki natomiast zazwyczaj miały ujemne stopy zwrotu. Wyniki modeli regresji liniowej ze zmiennymi binarnymi reprezentującymi efekt dnia tygodnia wskazały, że dni tygodnia mogą mieć istotny wpływ na stopy zwrotu, zwłaszcza dla niektórych kryptowalut (BNB i BAT). Wprowadzenie do modeli równania wariancji warunkowej poprawiło jakość estymatorów i zmniejszyło błędy ocen parametrów. W przypadku równania wariancji warunkowej tylko w jednym przypadku stwierdzono efekt dnia tygodnia. Była to kryptowaluta BNB.

Analiza reakcji inwestorów w sytuacjach nadzwyczajnych wykazała, że inwestorzy inwestujący w aktywa klasyczne są bardziej podatni na wywoływanie paniki i wyprzedaże na rynkach akcji, podczas gdy inwestorzy inwestujący w aktywa alternatywne są mniej podatni na wpływ zewnętrznych informacji.

Analiza wolumenu obrotów wykazała, że różne kryptowaluty miały różne średnie stopy zwrotu oraz poziomy zmienności. Korelacja między ceną zamknięcia a wolumenem obrotu była umiarkowana dla niektórych kryptowalut, podczas gdy korelacja między zmiennością stóp zwrotu a wolumenem obrotu była niewielka. Testy

przyczynowości Grangera wykazały, że niektóre kryptowaluty wykazują przyczynowość w sensie Grangera dla innych kryptowalut.

Podsumowując, przeprowadzone analizy potwierdziły, że istnieją pewne podobieństwa między giełdami tradycyjnymi a rynkami kryptowalut. Efekty kalendarzowe (efekt dnia tygodnia) miały istotny wpływ na stopy zwrotu, ale nie we wszystkich przypadkach. Inwestorzy reagują różnie w sytuacjach nadzwyczajnych, a wolumen obrotu wpływa na zmienność stóp zwrotu. Ważnym wynikiem uzyskanym w przeprowadzonych badaniach jest to, że kryptowaluty okazały się lepszą formą inwestycji w sytuacji kryzysowej, jakiej był wybuch wojny na Ukrainie. Dlatego też ważne jest, aby inwestorzy rozważali w swych działaniach także możliwość inwestycji na tym rynku.

# Spis rysunków

Rysunek 1. Okna w analizie zdarzeń .....	22
Rysunek 2. Poziom BTC na zamknięcie notowań w okresie od 1.01.2018 do 31.12.2022 .....	26

# Spis tabel

Tabela 1. Charakterystyki dla dziennych stóp zwrotu wybranych kryptowalut wraz z wartościami podstawowych statystyk opisowych w okresie od 1.01.2018 do 31.12.2022 dla całej próby oraz w zależności od dnia tygodnia .....	30
Tabela 2. Przeciętne dzienne stopy zwrotu dla kryptowalut w rozbiciu na roczne podokresy .....	31
Tabela 3. Wyniki estymacji modeli regresji .....	33
Tabela 4. Wybuch wojny między Rosją a Ukrainą 2022-02-24 .....	34
Tabela 5. Wybrane statystyki dla całej próby .....	35
Tabela 6. Współczynniki korelacji ceny zamknięcia z wolumenem obrotu .....	36
Tabela 7. Współczynniki korelacji stóp zwrotu z wolumenem obrotu .....	36
Tabela 8. Współczynniki korelacji zmienności stóp zwrotu z wolumenem obrotu .....	36
Tabela 9. Wyniki testu ADF dla całego okresu .....	37
Tabela 10. Wyniki testu ADF dla poszczególnych podokresów .....	37
Tabela 11. Wyniki testu Johansena .....	38
Tabela 12. Test przyczynowości w sensie Grangera dla stóp zwrotu .....	38
Tabela 13. Test przyczynowości w sensie Grangera dla całego okresu badawczego ....	39
Tabela 14. Test przyczynowości w sensie Grangera dla poszczególnych podokresów badawczych .....	40

# Bibliografia

ANGHEL, D.-G., 2021. A reality check on trading rule performance in the cryptocurrency market: Machine learning vs. technical analysis. *Finance Research Letters*, Volume 39.

Ballis, A. & Verousis, T., 2022. Behavioural finance and cryptocurrencies. *Review of Behavioral Finance*, 14(4), pp. 545-562.

Bariviera, A. F., 2017. The inefficiency of Bitcoin revisited: A dynamic approach. *Economics Letters*, Volume 161, pp. 1-4.

Bartos, J., 2015. DOES BITCOIN FOLLOW THE HYPOTHESIS OF EFFICIENT. *International Journal of Economic Sciences*, IV(2).

Berument, H. & Kiymaz, H., 2001. The Day of the Week Effect on Stock Market Volatility. *JOURNAL OF ECONOMICS AND FINANCE*, 25(2), pp. 181-193.

Bhambhwani, S. M., Delikouras, S. & Korniotis, G. M., 2019. *Do Fundamentals Drive Cryptocurrency Prices?*, Miami: Miami Herbert Business School.

Binance, 2019. *Binance*. [Online]  
Available at: <https://academy.binance.com/pl/articles/what-is-fiat-currency>  
[Accessed 6 Kwiecień 2023].

Binance, 2021. *Binance Blog*. [Online]  
Available at: <https://www.binance.com/en/blog/fiat/fiat-money-vs-cryptocurrency-can-they-coexist-421499824684902103>  
[Accessed 19 lipiec 2022].

Bollerslev, T., 1986. Generalized Autoregressive Conditional Heteroscedasticity. *Journal of Econometrics*, 31(3), pp. 307-327.

Borkowski, B., Dudek, H. & Szczesny, W., 2007. *Ekonometria. Wybrane zagadnienia*. 1st ed. Warszawa: Wydawnictwo Naukowe PWN.

Box, G. & Jenkins, G., 1986. *Analiza szeregów czasowych : prognozowanie i sterowanie*. Warszawa: Państwowe Wydawnictwo Naukowe.

Business, 2022. *Business Insider*. [Online]  
Available at: <https://businessinsider.com.pl/gielda/jak-dzialaja-kopalnie-kryptowalut/48j622b>  
[Accessed 7 Kwiecień 2023].

Business, N. U. D.-M. S. o., 2018. *GUIDE TO THE RISE OF CRYPTOCURRENCY, DIGITAL CURRENCY AND BITCOIN*. [Online]  
Available at: <https://onlinebusiness.northeastern.edu/masters-in-finance-msf/knowledge/guide-to-the-rise-of-cryptocurrency-digital-currency-and-bitcoin/>  
[Accessed 19 lipiec 2022].

- Caporale, G. M. & Plastun, A., 2019. The day of the week effect in the cryptocurrency market. *Finance Research Letters*, Volume 31.
- Caporale, G. M. & Plastun, A., 2019. The day of the week effect in the cryptocurrency market. *Finance Research Letters*, Volume 31.
- Carrick, J., 2016. Bitcoin as a Complement to Emerging Market Currencies. *Emerging Markets Finance and Trade*, 52(10), pp. 2321-2334.
- Charemza, W. & Deadman, D., 1997. *Nowa ekonometria*. Warszawa: Polskie Wydawnictwo Ekonomiczne.
- Cheung, A., Roca, E. & Su, J.-J., 2015. Crypto-currency bubbles: an application of the Phillips–Shi–Yu (2013) methodology on Mt. Gox bitcoin prices. *Applied Economics*, 47(23), pp. 2348-2358.
- Cross, F., 1973. The Behavior of Stock Prices on Fridays and Mondays. *Financial Analysts Journal*, Volume 29, pp. 67-69.
- Cross, F., 1973. The Behavior of Stock Prices on Fridays and Mondays. *Financial Analyst Journal*, 29(6), pp. 67-69.
- Diaconășu, D.-E., Mehdian, S. & Stoica, O., 2022. *An analysis of investors' behavior in Bitcoin market*, Hiszpania: PLoS ONE.
- Dwyer, G., 2015. The economics of Bitcoin and similar private digital currencies. *Journal of Financial Stability*, Volume 17, pp. 81-91.
- Fields, 1931. Stock prices: a problem in verification. *The Journal of Business of the University of Chicago*, Volume 4, pp. 415-418.
- Fleischer, J., Laszewski, G., Theran, C. & Bautista, Y. J. P., 2022. *Time Series Analysis of Blockchain-Based Cryptocurrency Price Changes*, Ithaca: Cornell University.
- French, K., 1980. Stock Returns and the Weekend Effect., *Journal of Financial*, 8(1), pp. 55-69.
- Gurgul, J., 2012. *Analiza zdarzeń na rynkach akcji*.. Warszawa: Wolters Kluwer.
- Howells & Bain, 1999. *Money, Banking and Finance*. London: Longman.
- Ilham, R. N., Sinta, I. & Sinurat, M., 2022. THE EFFECT OF TECHNICAL ANALYSIS ON CRYPTOCURRENCY INVESTMENT RETURNS WITH THE 5 (FIVE) HIGHEST MARKET CAPITALIZATIONS IN INDONESIA. *Jurnal Ekonomi*, 11(2), pp. 1022-1035.
- Kang, H. J., 2022. Information efficiency in the cryptocurrency market. *Journal of Computer Information Systems*, pp. 622-632.
- Kravin, 2003. Determination of the Appropriate Event Window Length in Individual Stock Event Studies. *SSRN Electronic Journal*.
- Kufel, T., 2011. *Rozwiązywanie problemów z wykorzystaniem programu GRET*L. 3rd ed. Warszawa: Wydawnictwo Naukowe PWN.

Kujawa, S. & Ostrowska, E., 2016. Analiza zdarzeń i jej zastosowanie w finansach behawioralnych. *Finance, Rynki Finansowe, Ubezpieczenia*, pp. 191-200.

Landmesser, J., 2006. *EFEKT DNIA TYGODNIA NA GIEŁDZIE PAPIERÓW WARTOŚCIOWYCH W WARSZAWIE*, Warszawa: s.n.

Latif, S. R., 2017. Testing the Weak form of Efficient Market in Cryptocurrency. 12(9), pp. 2285-2288.

Maddala, G. S., 2008. *Ekonometria*. Warszawa: Wydawnictwo Naukowe PWN.

Mnif, E., Salhi, B., Mouakha, K. & Jarboui, A., 2022. Investor behavior and cryptocurrency market bubbles during the COVID-19 pandemic. *Review of Behavioral Finance*, 14(4), pp. 491-507.

Oracle, 2022. *Oracle*. [Online]  
Available at: <https://www.oracle.com/pl/blockchain/what-is-blockchain/>  
[Accessed 6 Kwiecień 2023].

Oracle, 2023. *Oracle*. [Online]  
Available at: <https://www.oracle.com/pl/blockchain/what-is-blockchain/>  
[Accessed 13 Luty 2023].

Osińska, M., 2008. *Ekonometryczna analiza zależności przyczynowych*. 1st ed. Toruń: Wydawnictwo Naukowe Uniwersytetu Mikołaja Kopernika.

Ostasiewicz, S., Rusnak, Z. & Siedlecka, U., 1998. In: *Statystyka. Elementy teorii i zadania*. Wrocław: Wydawnictwo Uniwersytetu Ekonomicznego we Wrocławiu, p. 276.

Piontek, K., 2002. *Modelowanie i prognozowanie zmienności instrumentów finansowych*, Wrocław: Akademia Ekonomiczna we Wrocławiu.

Piontek, K., 2003. Modelowanie "długiej pamięci" szeregów zmienności stóp zwrotu. *Prace Naukowe / Akademia Ekonomiczna w Katowicach*, pp. 491-504.

Plastun, A., Kozmenko, S., Plastun, V. & Filatova, H., 2019. Market anomalies and data persistence: The case of the day-of-the-week effect. *Journal of International*, Issue 12, pp. 122-130.

Sigaki, H. Y., Perc, M. & Ribeiro, H. V., 2019. Clustering patterns in efficiency and the coming-of-age of the cryptocurrency market. *Scientific Reports*, Issue 9.

Software Testing Help, 2023. *Software Testing Help*. [Online]  
Available at: <https://www.softwaretestinghelp.com/types-of-cryptocurrency/>  
[Accessed 13 Luty 2023].

Svogun, D. & Bazán-Palomino, W., 2022. Technical analysis in cryptocurrency markets: Do transaction costs and bubbles matter?. *Journal of International Financial Markets, Institutions and Money*, Volume 79.

Tarczyński, W., 2002. *Fundamentalny portfel papierów wartościowych*. Warszawa: Polskie Wydawnictwo Ekonomiczne.



- TradeStation, 2020. *TradeStation*. [Online] Available at: <https://www.tradestation.com/learn/market-basics/cryptocurrencies/the-basics/how-does-crypto-compare-to-traditional-currency/> [Accessed 19 lipiec 2022].
- Trading Jam, 2018. *Analiza techniczna a cena, Rafał Zaorski, #4 Traderzy dla Traderów* [Interview] (9 lipiec 2018).
- Tsay, R., 2002. *Analysis of Financial Time Series*. 2nd ed. Chicago: Wiley and Sons.
- Wei, M., Kyriakou, I., Sermpinis, G. & Stasinakis, C., 2023. *Cryptocurrencies and Lucky Factors: the Value of Technical and Fundamental Analysis*, s.l.: s.n.
- Widz, E., 2017. Stopy zwrotu indeksów giełdowych na GPW w Warszawie i ich zmienność a wolumen obrotu akcjami – analiza zależności. *Finanse, Rynki Finansowe, Ubezpieczenia*, pp. 401-412.
- Yaya, O. & Ogbonna, A. E., 2019. *Do we Experience Day-of-the-week Effects in Returns and Volatility of Cryptocurrency?*, s.l.: University of Ibadan.
- Zaremba, A. & Płotnicki, M., 2015. Krótkoterminowe i długoterminowe reakcje cenowe na ogłoszenia transakcji fuzji i przejęć na rynkach Europy Środkowo-Wschodniej. *ZESZYTY NAUKOWE UNIwersytetu SZCZECIŃSKIEGO*, Volume 854, pp. 593-606.
- Zielonka, P., 2006. *Behawioralne aspekty inwestowania na rynku papierów wartościowych*. 6th ed. Warszawa: CeDeWu.



Wyrażam zgodę na udostępnienie mojej pracy w czytelniach Biblioteki SGGW  
w tym w Archiwum Prac Dyplomowych SGGW.

.....

*(czytelny podpis autora pracy)*